



Bases de TAL

Master 1 Sciences du Langage
Parcours Industries de la Langue – Linguistic Data Sciences

Martina Barletta
3-6 septembre 2024







Table des contenus

01

Introduction

au Traitement
Automatique des Langues

02

Histoire du TAL

Du rapport ALPAC à
ChatGPT

03

Tâches

Et campagnes
d'évaluation

04

Evaluation

Comment on évalue des
systèmes TAL et
l'annotation des données ?

05


Métriques

Pourquoi et comment
évaluer correctement ?

06


Exposé

sur les thématiques
du cours



Speech and Language Processing

Dan Jurafsky et James H. Martin
Full version available online!







03

Tâches

Et chaîne de traitement



Réduire la langue à des problèmes calculables

Se soucier d'un problème à la fois
pour ne pas s'occuper de la
langue comme système



Le problème général est
divisé
en plusieurs sous-
problèmes plus petits

Théorie de la calculabilité →
définir les limites de ce qui peut
être calculé à travers un algo \neq
Théorie de la complexité → définir
quelle est l'efficacité d'un
algorithme

Chaîne de traitement en TAL

Module

Manipulations de l'objet texte
pour identifier et/ou étiqueter
des objets linguistiques
à différents niveaux textuels



Comment tokeniser un texte ?

En juillet 1799, les soldats de l'armée de Napoléon découvraient près de la ville de Rosette, sur le delta du Nil, une pierre qui allait devenir l'une des plus célèbres de l'Antiquité.

Cette pierre, datant de 196 av. J.-C., relatait les honneurs rendus au roi Ptolémée V par les temples d'Égypte sous forme d'un "texte parallèle" en deux langues (le grec et l'égyptien) et trois écritures (les textes égyptiens étant écrits à la fois en hiéroglyphes et en démotique).

Son étude permit à Jean-François Champollion d'apporter en 1822 la clé du déchiffrement de l'écriture hiéroglyphique, découverte qui eut un retentissement considérable car elle mettait fin aux nombreuses controverses et mythes qui avaient entouré cette écriture.

Comment tokeniser un texte ?

1. Tokenisez la première phrase du texte à la main
2. Téléchargez le texte veronis.txt sur github
3. Utilisez le fichier comme fichier d'entrée sur <https://corliapi.ortolang.fr/stanza/> (option écrit)
4. Téléchargez le fichier CoNLL-U et comparez-le avec votre tokenisation

Le mot en TAL (plutôt, token)

- Passer d'une suite de caractères à une suite de **formes** → découpage en **TOKEN**
 - Séparés par des espaces ? **Pomme de terre**
 - Par des signes de ponctuation ? Chauve-souris, aujourd'hui, I'm en anglais
 - Constitués ou qui commencent par de signes de ponctuation ? ☺, #nplrules
- Certains tokens ne sont pas forcément des mots
 - Chiffres, dates, heures...
 - Acronymes
 - LA PONCTUATION !!! (*Let's eat, grandma* VS *Let's eat grandma*)
- Pas toutes les langues utilisent des espaces pour découper leurs mots (japonais)
- Dans la langue parlée, les disfluences ou les fillers, sont-ils des tokens ?

Plusieurs types de tokenisation

"Don't you love 😊 Transformers? We sure do."

- Sur les espaces

["Don't", "you", "love", "😊", "Transformers?", "We", "sure", "do."]

- Token = mot (au sens linguistique) et ponctuation

["Don", "'", "t", "you", "love", "😊", "Transformers", "?", "We", "sure", "do", "."]

- Espaces, ponctuation et tokenisation à base de règles

["Do", "n't", "you", "love", "😊", "Transformers", "?", "We", "sure", "do", "."]

- Autres algorithmes (Byte-Pair Encoding)

https://huggingface.co/docs/transformers/tokenizer_summary

Lemmatisation

- Obtenir la forme canonique ou lemme d'un mot à partir d'une forme donnée
 - Verbe – forme à l'infinitif (sans flexion)
 - Il court → courir
 - Pour un nom, adjectif, article, ... - forme au masculin singulier
 - Cheval, chevaux → cheval
- La lemmatisation demande des ressources et un traitement linguistique (couteuse)
- Elle permet d'agréger des variantes flexionnelles et non pas des mots ayant la même racine

Stemming (racinisation)

- Obtenir la racine d'un mot, commune à toutes les variantes morphologiques d'un mot à travers la suppression des flexions et des suffixes
- Elle est généralement à base de règles, rapide et dépends de la langue
- Demande moins de ressources que la lemmatisation (vocabulaire plus petit)

Annotation

Segmenter un texte en plusieurs sous-unités et associer une étiquette aux unités qui nous intéressent traiter

Annoter tous les tokens d'un texte et associer une ou plusieurs étiquettes à chaque token

POS-tagging

Délimiter des tokens ou suite de tokens dans les textes et leur associer des étiquettes

Entités nommées
Coréférence

Annotation (I)

- L'annotation servait à fournir des informations pour le développement et mise à l'épreuve des théories en linguistique, ou, comment on l'appelle aujourd'hui, à la linguistique des corpus (...) ces ressources servent aujourd'hui à la linguistique mais aussi au traitement automatique des langues (...)

(Ide, Handbook of linguistic annotation, 2017)

Annotation (II)

- Associer à chaque token une ou plusieurs étiquettes
- Délimiter un token ou ensemble de tokens et associer une étiquette

Annotation (III)

- Associer à chaque token une ou plusieurs étiquettes

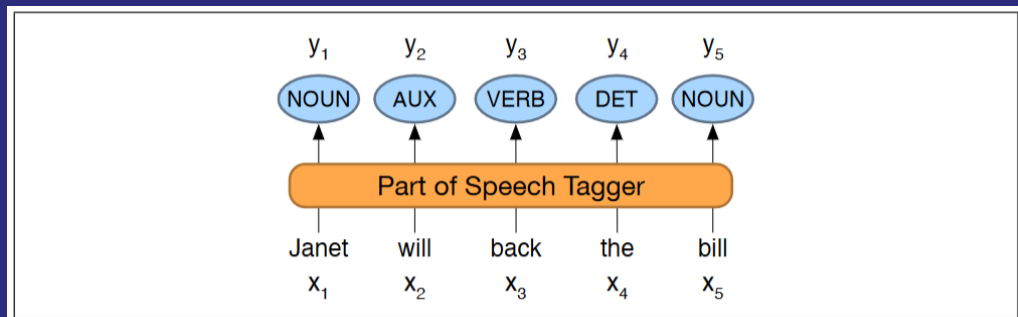
“Such tasks in which we assign, to each word x_i in an input word sequence, a label y_i , so that the output sequence Y has the same length as the input sequence X are called **sequence labeling tasks**.” (Jurafsky et Martin, 2008)

- Étiquetage morphosyntaxique
 - Lemmatisation
 - Traits morphosyntaxiques
- La **précision** des algorithmes d’annotation morphosyntaxique est actuellement très haute (autour du 97%)

POS tagging

Associer à un token sa catégorie morphosyntaxique
(nom, verbe, adjectif, adverbe etc.)

- Utile dans l'élimination des stop words
- Regroupement de termes complexes
- Désambiguïsation
- Construire une représentation syntaxique du texte



(Stop Words)

- Mots vides en français (prépositions, articles, pronoms...)
- Sa distribution est uniforme sur les textes du corpus – sa fréquence est similaires dans tous les textes d'un corpus → mots qui ne sont pas discriminants dans le significat du texte
- Pour certaines tâches, on peut les retirer des textes pour faciliter le traitement
- BONUS : allez regarder la loi de Zipf !

Exo POS tagging

Le chat mange la souris

La pomme de terre n'était pas connue
en Amérique avant 1596.

La petite porte le voile

Tagset : DET, NOUN, ADJ, VERB, PRON...
(formalisme UD)

Quelles versions de la dernière phrase sont
possibles ?

Open class words	Closed class words	Other
ADJ	ADP	PUNCT
ADV	AUX	SYM
INTJ	CCONJ	X
NOUN	DET	
PROPN	NUM	
VERB	PART	
	PRON	
	SCONJ	

Le – DET
chat – NOUN
mange – VERB
la – DET
souris – NOUN
. – PUNCT

La – DET
pomme de terre – NOUN ?
 pomme – NOUN
 de – ADP
 terre – NOUN

n' – ADV
était – AUX
pas – ADV
connue – VERB
en – ADP
Amérique – PROPN
avant – ADP
1596 – NUM
. – PUNCT

Open class words	Closed class words	Other
<u>ADJ</u>	<u>ADP</u>	<u>PUNCT</u>
<u>ADV</u>	<u>AUX</u>	<u>SYM</u>
<u>INTJ</u>	<u>CCONJ</u>	<u>X</u>
<u>NOUN</u>	<u>DET</u>	
<u>PROPN</u>	<u>NUM</u>	
<u>VERB</u>	<u>PART</u>	
	<u>PRON</u>	
	<u>SCONJ</u>	

La - DET
petite - ADJ
porte - NOUN
le - PRON
voile - VERB



La - DET
petite - NOUN
porte - VERB
le - DET
voile - NOUN



Annotation (II)

- Délimiter un token ou ensemble de tokens et associer une étiquette

Le phénomène qu'on veut annoter est « dilué » dans le texte, il faut d'abord le délimiter puis associer l'étiquette nécessaire

- Entités nommées
- Coréférence
- Sentiment analysis
- Hate speech
- Toxic content

Entités nommées

Les noms propres (PROPN) sont habituellement des unités polylexicales (Multi Word Phrases)

Named entity – entité qui peut être indiquée à travers un nom propre
Personne, lieu, organisation...

Ex. Marie Curie, Léon Marchand, New York, Université Grenoble Alpes

NER – named entity recognition → trouver des empanes de texte qui représentent des noms propres et étiqueter le type d'entité représenté

Exo entités nommées

TAGSET : PER, LOC, ORG, TIME, MONEY

Citing high fuel prices, United Airlines said Friday it has increased fares by \$6 per round trip on flights to some cities also served by lower-cost carriers. American Airlines, a unit of AMR Corp., immediately matched the move, spokesman Tim Wagner said. United, a unit of UAL Corp., said the increase took effect Thursday and applies to most routes where it competes against discount carriers, such as Chicago to Dallas and Denver to San Francisco.

Solution

Citing high fuel prices, [ORG **United Airlines**] said [TIME **Friday**] it has increased fares by [MONEY **\$6**] per round trip on flights to some cities also served by lower-cost carriers. [ORG **American Airlines**], a unit of [ORG **AMR Corp.**], immediately matched the move, spokesman [PER **Tim Wagner**] said. [ORG **United**], a unit of [ORG **UAL Corp.**], said the increase took effect [TIME **Thursday**] and applies to most routes where it competes against discount carriers, such as [LOC **Chicago**] to [LOC **Dallas**] and [LOC **Denver**] to [LOC **San Francisco**].

Entités nommées

AstroERC

Extension du corpus TDAC (Time-Domain Astrophysic Corpus)
Alkaan et al., 2024

Annotation des entités nommées, la coréférence et les relations
sémantiques dans un corpus d'astrophysique composé de 300
rapports d'observation en anglais

AstroERC

We discovered PS19did on MJD 58666.31 = 2019-07-02.31 at w=19.9 +/- 0.1 mag.

[...] The new transient source is in the galaxy UGC 11003.

[...] A spectrum was obtained of the possible supernova with the 1.82-m Plaskett telescope.

[...] Adopting the host galaxy redshift z=0.03566 (NED) yields an expansion velocity...

[...] Followup observations of this intrinsically faint transient are encouraged.

We discovered PS19did on MJD 58666.31 = 2019-07-02.31 at w=19.9 +/- 0.1 mag.

[...] The new transient source is in the galaxy UGC 11003.


[...] A spectrum was obtained of the possible supernova with the 1.82-m Plaskett telescope.




[...] Adopting the host galaxy redshift z=0.03566 (NED) yields an expansion velocity...






[...] Followup observations of this intrinsically faint transient are encouraged.

FIGURE 1 – Extrait d'un rapport d'observation. A gauche, un exemple d'annotation en entités nommées uniquement, et à droite, l'annotation des entités nommées avec en plus l'annotation des mentions de coréférences et des relations sémantiques entre les objets célestes (mentions de type `CelestialObject`) et leurs propriétés physiques.






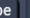






Pour quel but ?



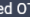










 Astro-COLIBRI












































Personalize 

Status: logged out Infos: ✓ v2.16.0

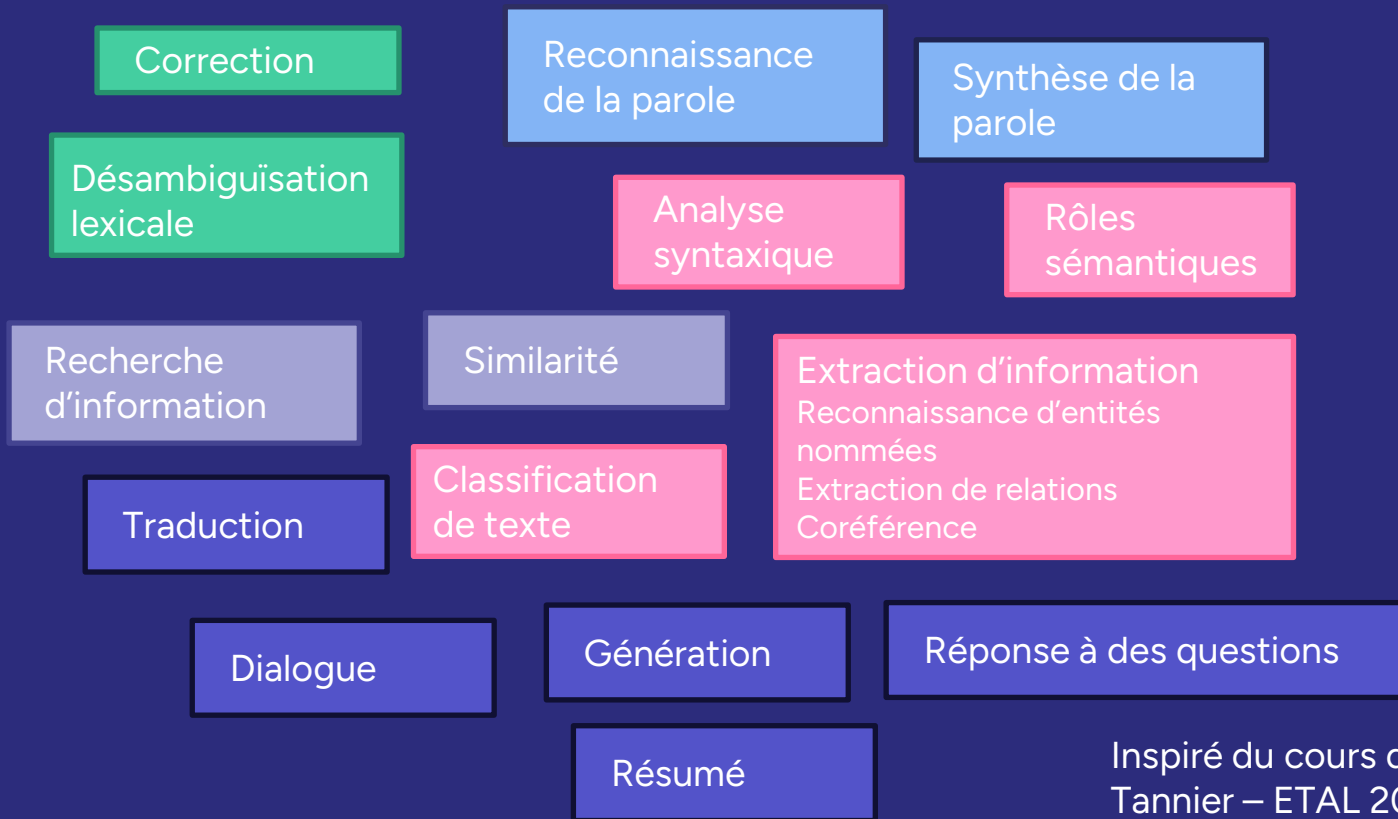
Observatories  Swift  SVOM  Fermi  HAWC  IceCube  AMON  Integral  GECAM  FlaapLUC  LVC  Catalogs  Other

Event type  FRB  Unclassified OT  Classified OT  SN  GRB  burst  neutrino  nuem  GW  4FGL  TeV CAT  SGR/AXP  IceCat General

 2024-08-20 



La notion de TASK en TAL



Inspiré du cours de X.
Tannier – ETAL 2021

Shared task

- Campagnes qui rassemblent chercheurs et industriels
- Trouver une solution à un problème commun en utilisant le même jeu de données et les mêmes métriques d'évaluation (framework pas toujours défini)

Chaque équipe propose un système, entraîné (habituellement) sur un jeu de données commun (gold standard annotation), évalué sur un jeu de données commun (blind dataset parfois) et selon les mêmes métriques.

SemEval – International Workshop on Semantic Evaluation

CoNLL – **SIGNLL conference on Computational Natural Language Learning**

FakeNewsChallenge

EVALITA (Italie)

DEFT fouille de texte (France)

Benchmark

- Benchmark → mesurer et comparer la performance des modèles sur une tâche ou un ensemble de tâches

EVALITA 2023

- Affect

- EMit – Categorical Emotion Detection in Italian Social Media (O. Araque, S. Frenda, D. Nozza, V. Patti, R. Sprugnoli)
- EmotivITA – Dimensional and Multi-dimensional emotion analysis (G. Gafà, F. Cutugno, M. Venuti)

- Authorship Analysis

- PoliticiT – Political Ideology Detection in Italian Texts (D. Russo, S.M. Jiménez-Zafra, J.A. García-Díaz, T. Caselli, M. Guerini, L.A. Ureña-López, R. Valencia-García)
- GeoLingIt – Geolocation of Linguistic Variation in Italy (A. Ramponi, C. Casula)
- LangLearn – Language Learning Development (C. Alzetta, D. Brunato, F. Dell’Orletta, A. Miaschi, K. Sagae, C.H. Sánchez-Gutiérrez, G. Venturi)

EVALITA 2023

- Computational Ethics

- HaSpeede 3 – Political and Religious Hate Speech Detection (M. Lai, F. Celli, A. Ramponi, S. Tonelli, C. Bosco, V. Patti)
- HODI – Homotransphobia Detection in Italian (D. Nozza, G. Damo, A.T. Cignarella, T. Caselli, V. Patti)
- MULTI-Fake-DetectiVE – MULTImodal Fake News Detection and VERification (A. Bondielli, P. Dell'Oglio, A. Lenci, F. Marcelloni, L.C. Passaro)
- ACTI – Automatic Conspiracy Theory Identification (G. Russo, N. Stoehr, M. Horta Ribeiro)

- New Challenges in Long Standing Tasks

- NERMuD -Named-Entities Recognition on Multi-Domain Documents (T. Paccosi, A. Palmero Aprosio)
- CLinkaRT – Linking a Lab Result to its Test Event in the Clinical Domain (B. Magnini, B. Altuña, A. Lavelli, M. Speranza, R. Zanolì)
- WiC-ITA – Word-in-Context task for Italian (P. Cassotti, L. Siciliani, L. Passaro, M. Gatto, P. Basile)
- DisCoTEX – Assessing DIScourse COherence in Italian TEXTs (D. Brunato, D. Colla, F. Dell'Orletta, I. Dini, D.P. Radicioni, A.A. Ravelli)

DEFT 2024

Défi Fouille de Textes@TALN 2024

- Réponse automatique à des questionnaires à choix multiples issus d'annales d'examens de pharmacie
- Corpus : FrenchMedMCQA
- FrenchMedQA – 3105 question fermées composés de :
 - Un identifiant
 - La question
 - Cinq options
 - L'ensemble des réponse(s) correcte(s)

DEFT 2024

Défi Fouille de Textes@TALN 2024

- Deux tâches :
 - Tâche principale – identifier l'ensemble des réponses correctes parmi les cinq proposées pour une question donnée. Moins de 3 milliards de paramètres
 - Tâche annexe : pareil mais pas de limites sur la taille des modèles
- Métriques :
 - Exact Match Ratio (taux des réponses parfaitement justes)
 - Hamming Score (taux des réponses juste parmi l'ensemble des réponses et référence)

L'importance des campagnes d'évaluation...

- Permettent de faire avancer la recherche sur des thématiques spécifiques à travers la compétition
- Problèmes éthiques, entre autres le manque de ressource adéquates pour certaines équipes (ordinateurs assez puissants)
- Les gagnants parfois ne publient pas de manière claire (*secretiveness*)
- Manque de description des résultats négatifs (ne permet pas d'avancer)
- Certaines équipes se retirent des compétitions si pas bien placés pour ne pas nuire à leur réputation – surtout dans l'industrie
- Plutôt que trouver une vraie solution, on s'occupe d'adapter notre système à un data set existant et à le mesurer avec la métrique prévue

Annotation de la continuité référentielle dans un corpus scolaire

Résultats préliminaires



1.

Contexte

**Recherche doctorale, état de l'art
et corpus existants**

Contexte de la recherche

*Étude des phénomènes de cohérence et cohésion textuelle dans un corpus d'écrits
d'élèves d'école primaire
longitudinal et comparable en français, italien et espagnol*

Problématiques :

- Comment la **cohérence/cohésion textuelle** se construit à l'école primaire dans les trois langues ?
 - Quelles sont les différences et similarités entre les trois langues ?
 - Comment la décrire de manière empirique
pour nourrir la réflexion et les pratiques en didactique de l'écriture ?

Méthodologie :

➤ *Annotation comparable
des chaînes de continuité référentielle*

Focus sur la coréférence

Extraction d'information - Coréférence

Une sorcière avait une maison noire et un chat noir. Il se cachait dans la maison pour ne pas qu'on le voie. Il ne sortait que la nuit. Un jour la sorcière en avait marre. Avec sa baguette magique elle l'a transformé en chat vert comme ça elle le voyait tout le temps.


Texte normalisé tiré du corpus Scoledit, CE2, élève 207

Une sorcière > la sorcière > sa > elle > elle

un chat noir > Il > le > Il > l' > chat vert > le

- Continuité référentielle – dans notre travail, *ensemble des expressions linguistiques utilisées par l'élève pour réaliser la présence de référents donnés dans l'univers d'un texte donné* (Garcia-Debanc et al., 2019 ; inspiré de T. Givón, 1983)
- Chaîne de référence – suite d'au moins trois expressions d'une production écrite ou orale qui renvoient à une même entité appartenant à l'univers du texte (Schneidecker, 1997, 2021) (Chastain, 1975 ; Corblin, 1985, 1995 ; Charolles, 1988)

Anaphore et coréférence



Anaphore

- (Corblin, 1995 ; Poesio, 2016)
- « suppose la mise en relation d'une expression non autonome du point de vue de la référence et d'une expression référentielle susceptible de la « saturer » (Schnedeker, 2019 p.11, Corblin, 1995)

Relation asymétrique

Coréférence

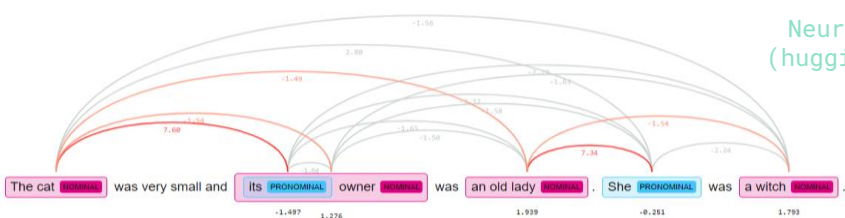
- « forme d'identité référentielle entre les référents évoqués » (Schnedeker, 2019, p. 13)

Relation symétrique

Utilité de la résolution de corréférence

- Systèmes de dialogue
- Réponse aux questions
- Traduction automatique
- Text summarization (de quoi on parle dans un texte)?
- Études sur le développement de l'écriture à l'école primaire

Outils « off the shelf »



Neuralcoref
(hugging face)

The cat was very small and its owner was an old lady. She was a witch.

Mémoire de Master 2
Linguistique Informatique Traduction, option Informatique

ODACR :

un Outil de Détection Automatique
des Chaînes de Référence
à base de règles linguistiques

rédigé par BRUNO OBERLÉ
sous la direction de Mme TODIRASCU

DeCOFre

passing pypi v0.7.0 code style black

Detecting Coreferences for Oral French¹.

This was developed for application on spoken French as part of my PhD thesis, it is relatively easy to apply it to other languages and genres, though.

Croc

Coreference Resolver for Oral Corpora

The documentation is in the [pdf file](#) (in french).

Please cite:
Désoyer, A., Landragin, F., Tellier, I., Lefevre, A. & Antoine, J.-Y.
(2014) "Les coréférences à l'oral : une expérience
d'apprentissage automatique sur le corpus ANCOR.",
Traitement Automatique des Langues (TAL) 55(2),
<http://www.atala.org/-Volume-55->, 2014, pp. 97-121.

SEARCH

reference resolution

Scholar About 2,660 results (0.09 sec)

Since 2021

Corpus annotés en coréférence en français



2019



2021

- ▶ Premier corpus de grand taille annoté et librement disponible en français
- ▶ Corpus en diachronie longue du 12^e au 21^e siècle
- ▶ Annotation des chaînes tout au long des textes – chaînes globales
- ▶ Exploitation par des outils TAL
- ▶ Corpus d'écrits scolaires annoté en continuité référentielle – écrits sollicités par la recherche
- ▶ S'inspire de Annodis et de DEMOCRAT
- ▶ Élaboration d'une cartographie des formes linguistiques qui manifestent la cohérence et cohésion textuelles
- ▶ Annotation limitée aux référents provoqués par la consigne

Landragin 2021, 2022 ; Landragin *et al.*, 2024

Garcia-Debanc *et al.*, 2021

Le corpus Scolinter



(Goigoux, 2016)
CP - CE1

Scoledit

(Wolfarth et al., 2017)
CP - CM2



(Ponton et al., 2021)

ANR - 2018 - 2022 Constitution de corpus d'écrits scolaires




RésolCo (Garcia-Debanc et al., 2017, 2021)

Ecriscol (Doquet, 2020)


Littéracie Avancée (Jacques & Rinck, 2017)

Le corpus Scolinter – textes récoltés


1




2



3




4



Voici 4 personnages. Choisis un ou deux personnages et raconte une histoire.
Entoure le ou les personnages que tu as choisis.

Consigne du CE1, CE2, CM1 et CM2



Constitution du corpus

Scan

Transcription


Normalisation



[x]^{C'est} l'histoire d'une sorsière dans sa chomière,
un jour quelle alai dans la forêt elle
rencontra un robot tout casé elle lenmena
dans sa maison elle le rèpara le robot
se rèvella la sorsière lui lanssa un
sore mais il ne marcha pas et se retourne
sur elle; quen elle se rèvella elle aiter
jantille. Fin

C'est l'histoire d'une sorcière dans sa chaumière. Un jour qu'elle allait dans la forêt elle rencontra un robot tout cassé, elle l'emmena dans sa maison et elle le répara. Le robot se réveilla. La sorcière lui lança un sort mais il ne marcha pas et se retourne sur elle ; quand elle se réveilla elle était gentille. Fin

Plateforme de visualisation du corpus

langue	Id étudiant	Niveau scolaire	Transcription	Normalisation
	844	0	3	
<p>il gatto e il lupo</p> <p>Cera una volta un piccolo gattino di nome bibi.</p> <p>Un giorno il piccolo gattino uscì delle sue case e andò nel bosco e sentì[x] qualcosa e era un lupo ma voleva mangiarlo, [x], ma il gatto corre corre e entrò in casa sua.</p> <p>-----</p> <p>il lupo, putto guì la porta, e il gatto corre ma si nascon[*****] il lupo la vede e poi il gatto e il lupo diventarono amici e vano tutto in sieme come: giocare, mangiare, correre, pescare, parlare, camminare</p>				<p>Il gatto e il lupo</p> <p>C'era una volta un piccolo gattino di nome Bibi.</p> <p>Un giorno il piccolo gattino uscì dalla sua casa e andò nel bosco e sentì qualcosa e era un lupo ma <i>voleva</i> mangiarlo, ma il gatto corre corre e entrò in casa sua. Il lupo buttò giù la porta, e il gatto corre ma si nasconde [•] il lupo lo vede e poi il gatto e il lupo diventarono amici e fanno tutto insieme come: giocare, mangiare, correre, pescare, parlare, camminare.</p>

Lien vers la plateforme : <https://scoledit.org/scolinter/corpus.php>

2.

Annotation

en continuité référentielle du corpus Scolinter

Guide d'annotation

- ▶ Annotation de toutes les mentions et les chaines provoquées par les personnages imposés par la consigne ou les entités ajoutées par l'élève
- ▶ Annotation de chaines, anaphores et singletons → *visée didactique*
- ▶ Étiquettes *cat*, *witch*, *wolf*, *robot*
- ▶ Étiquettes *extN* sur le texte si il y a des entités animées externes à la consigne

WITCH



CAT



ROBOT



WOLF



EXT-N

EXT1



EXT2



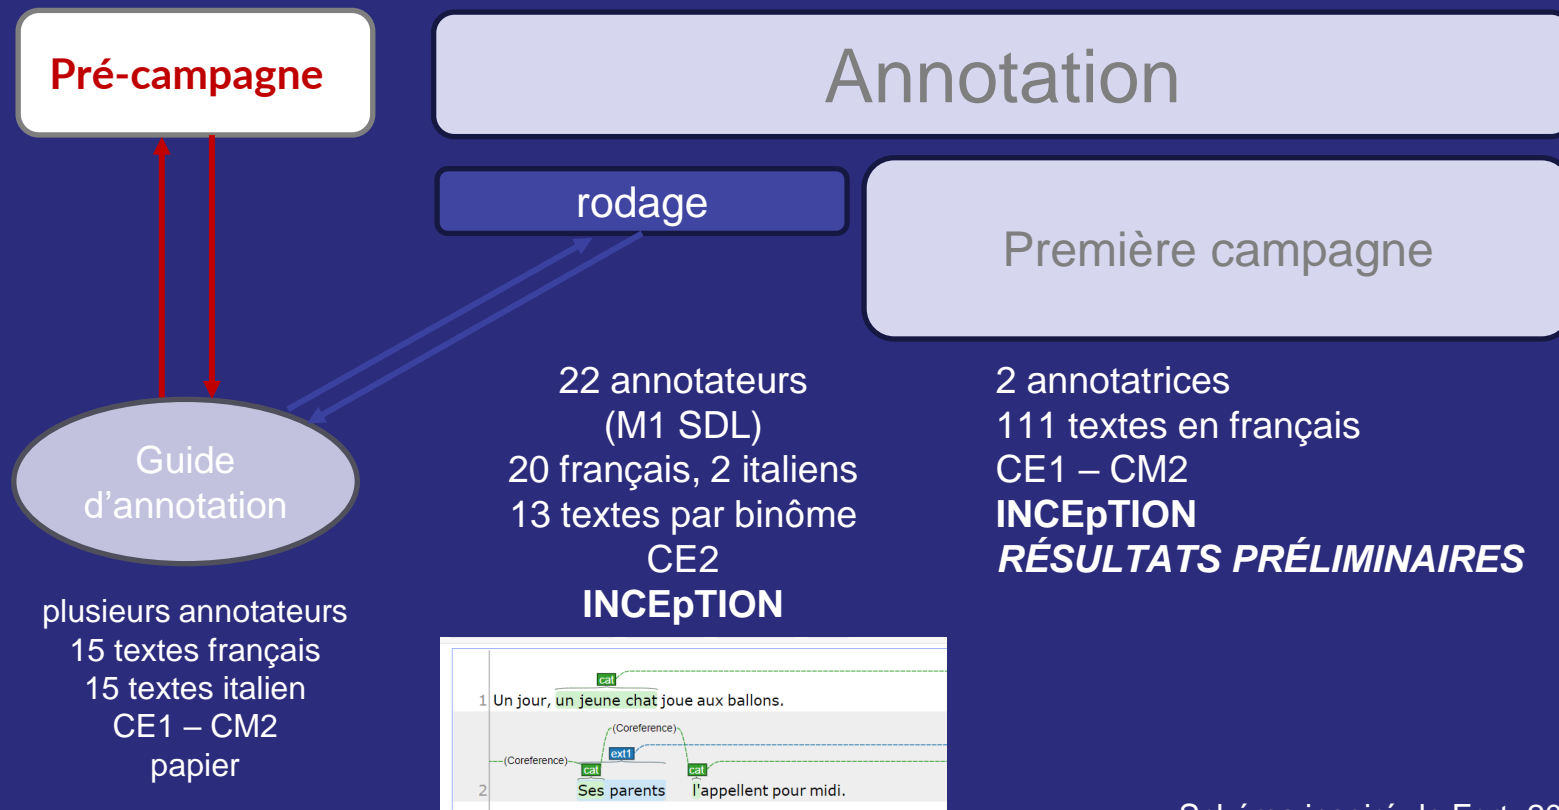
EXT3



EXT4...



Campagnes d'annotation




3.

Observations et résultats

Sur la première campagne d'annotation

Caractérisation du corpus de référence (I)

Niveau	Nb textes	Nb tokens	Nb moyen tokens par texte
CE1	32	2 388	74,63
CE2	25	3 475	139
CM1	27	4 541	168,19
CM2	27	5 979	221,44
Corpus	111	16 383	150,82




Caractérisation du corpus de référence (II)

Niveau	Maillons	Nb moyen de référents par texte	Densité référentielle (maillons/tokens)	Longueur moyenne des chaînes
CE1	461	2,21	19,3%	6,54
CE2	651	2,56	18,73%	10,68
CM1	868	3,11	19,11%	11,01
CM2	1 066	3,48	17,83%	11,60
Corpus	3 046	2,84	18,59%	9,96

Caractérisation du corpus de référence (II)

Comparaison de la densité et de la stabilité référentielle entre textes narratifs et non-narratifs dans le corpus DEMOCRAT. (Landragin *et al.*, 2024)

Niveau	Maillons	Nb moyen de référents par texte	Densité référentielle (maillons/tokens)
CE1	461	2,21	19,3%
CE2	651	2,56	18,73%
CM1	868	3,11	19,11%
CM2	1 066	3,48	17,83%
Corpus	3 046	2,84	18,59%




Caractérisation des mentions

Statistique sur toutes les mentions annotées (anaphore et singletons compris)

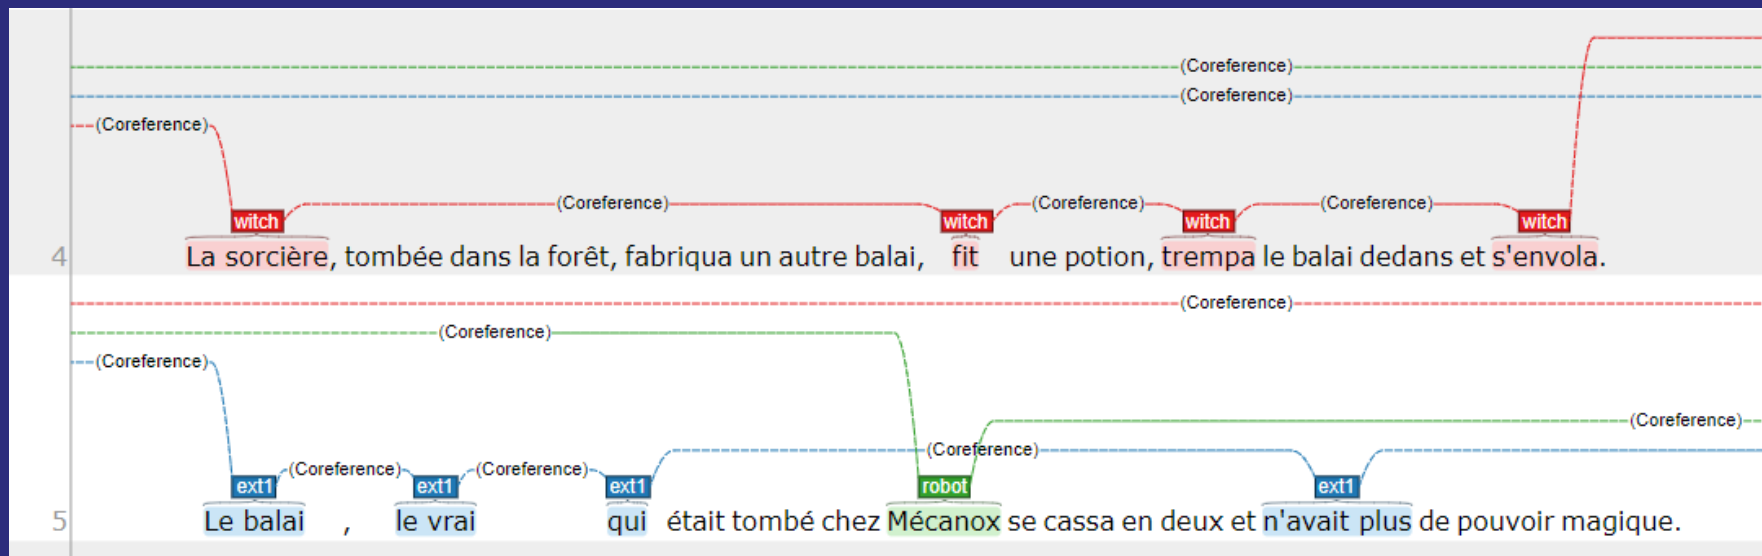
Type de mention	Nb	%
Pronoms	1 248	42,6%
Syntagmes nominaux définis	604	20,6%
Syntagmes nominaux indéfinis	272	9,3%
Déterminants Possessifs	226	7,7%
Noms propres	186	6,4%
Syntagmes nominaux sans déterminant	154	5,3%
Autre type	132	4,5%
<i>Anaphore zéro</i>	89	3%
<i>Syntagmes nominaux démonstratifs</i>	17	0,6%
Total	2 928*	

*Certaines mentions sont étiquetées plusieurs fois avec des référents différents, ici chaque mention est comptée une seule fois



Typologie des mentions inspirée de AnnoDis, cité par Federzoni *et al.*, 2021

Difficultés d'annotation : l'anaphore zéro en français



4.

Conclusions

Conclusions

- ▷ Densité référentielle cohérente avec textes narratifs de scripteurs experts (Landragin *et al.*, 2024)
- ▷ Anaphore zéro difficile à annoter
- ▷ Nouvelle campagne d'annotation en cours (juin-septembre 2024)

Perspectives en annotation

- ▷ Troisième campagne d'annotation :
 - 150 textes en italien : CE1 – CE2
 - 150 textes en français : CE1 – CE2
- ▷ Deux annotateurs pour le corpus français,
deux annotateurs pour le corpus italien
- ▷ Comparaison des résultats entre français et italien

Perspectives en évaluation

- ▷ Adjudication et calcul de l'accord interannotateur possibles sur INCEpTION (layer personnalisé)
- ▷ Garantir la fiabilité des données annotées (Fort, 2012 ; Mathet et Widlöcher, 2016)
 - évaluer la délimitation des mentions et l'attribution d'un référent (Mathet & Widlöcher, 2016 ; Quignard *et al.*, 2021) en utilisant γ - *gamma* (Mathet *et al.*, 2015)



04

Évaluation

(section inspiré du cours d'Initiation au TAL
Diapos de Olivier Kraif et Martina Barletta, 2023-2024)



L'annotation (encore une fois !)

- Cette étape consiste à enrichir les textes avec des données supplémentaires
- Elles peuvent être embarquées (codées dans le texte même) ou débarquées (codées à part)
- Ces annotations peuvent porter sur différents niveaux (texte, phrases, chunks, mots, caractères...)
- Elles permettent notamment de
 - construire, tester, évaluer des modèles TAL
 - évaluer un modèle linguistique
 - observer des phénomènes
 - etc.
- Il est important d'évaluer correctement cette étape pour mesurer la qualité des données (accords inter-annotateurs, silence/bruit) qui serviront aux analyses ultérieures

Mais avant tout, il faut évaluer ses données !

- À quel point mes données sont appropriées à ma tâche ?
- À quel point la couche d'annotation que j'ai rajoutée est-elle **fiable** ?
 - À quel points mes annotateurs sont **fiables** ?

La qualité de l'annotation ne peut pas être évaluée directement
On peut observer *l'accord* entre nos annotateurs selon les décisions prises

Si un seul annotateur → «carottages» sur les annotations de manière aléatoire

Si deux annotateurs :

- Conciliation entre les deux versions
- La version finale est le résultat de la décision d'un superannotateur expert

Comment calculer l'accord

- Différents coefficients possibles
- S (Bennet et al., 1954)
- π (Scott)
- κ (Cohen pour 2, Fleiss pour plus de 2 annotateurs)
- Alpha (Krippendorf)

K de Cohen

Calculé entre deux annotateurs (pairwise)

$$\kappa \equiv \frac{p_o - p_e}{1 - p_e} = 1 - \frac{1 - p_o}{1 - p_e}$$

p_o – proportion de l'accord entre 2 annotateurs

p_e – probabilité d'un accord aléatoire

Accord total $\rightarrow k = 1$

Désaccord total $\rightarrow k = 0$

$$p_e = \frac{1}{N^2} \sum_k n_{k1} n_{k2}$$

$p(e)$ – probabilité d'un accord aléatoire


N = observations à catégoriser

Nk_i – nb de fois où l'annotateur i a choisi la catégorie k

K de Cohen

K de Cohen


Interpretation of Kappa



<u>Kappa</u>	<u>Agreement</u>
< 0	Less than chance agreement
0.01–0.20	Slight agreement
0.21– 0.40	Fair agreement
0.41–0.60	Moderate agreement
0.61–0.80	Substantial agreement
0.81–0.99	Almost perfect agreement

05

INCEpTION




Exo en annotation de la coréférence

- Connectez-vous à <https://inception-demo.atilf.fr/>
- Username : prénom.nom
- Mdp : masteridl2024
- jamie.peake (Jamie Peake)
- auregan.nedelec (Auregan Nedelec)
- camille.lepelletier (Camille Lepelletier)
- camille.p (Camille Proust)

Scolinter - français 2024

Évaluation II



Définition d'évaluation

(en Traitement Automatique des Langues)

- Établir la qualité et la performance des modèles et des applications de TAL
- Mesurer à quel point l'application est capable de réaliser une tâche spécifique
- Pour mesurer la performance, on applique des métriques différentes selon la tâche et les objectifs de la tâche.



Pourquoi évaluer des systèmes TAL ?

L'évaluation des traitements du TAL est un enjeu très important : il existe de nombreuses méthodes pour résoudre un problème et de nombreuses manières de paramétrer un système, et la possibilité d'évaluer finement ses résultats est essentielle pour l'améliorer et en optimiser les performances.

Évaluation qualitative

- Examiner manuellement les sorties
- Analyser *qualitativement* le type d'erreur
 - Classer les erreurs
 - En expliquer la cause



Par ex. trouver des faux négatifs et des faux positifs



Évaluation quantitative

Les métriques

- Précision, rappel, f-measure
- Familles de métriques pour la traduction automatique
 - À chaque task, sa métrique





Métriques

Bruit – la proportion de faux positifs dans la sortie d'un système

Ex. La proportion de faux positifs dans un système de correction orthographique par rapport au nombre de mots identifiés.

Silence – la proportion de faux négatifs dans la sortie d'un système

Ex. La proportion de faux négatifs par rapport au nombre de mots à identifier comme erronées.



Métriques

Précision – le nombre d'étiquettes correctes sur le nombre d'étiquettes données

$$P = VP / (VP+FP)$$

Rappel – le nombre d'étiquettes correctes sur le nombre d'étiquettes attendues

$$R = VP / (VP+FN)$$

F-mesure – la moyenne harmonique de la précision et du rappel d'un système

$$F = 2PR / (P+R)$$

- BLEU (Bilingual Evaluation Understudy) – machine translation, question answering, summarization, text generation
- ROUGE (Recall-Oriented Understudy for Gisting Evaluation) – text generation, video captioning, summarization
- Perplexity
- METEOR (Metric for Evaluation of Translation with Explicit ORdering) – image and video captioning, text generation, question answering
- Word Error Rate (WER) – transcription automatique
- Exact match
- CIDEr (Consensus-based Image Description Evaluation)
- UAS (Unlabeled Attachment Score) – dependency parsers
- LAS (Labeled Attachment Score) – dependency parsers
- BERTscore...


Blagec et al., 2022

Coreference Resolution Metrics

- MUC-F
- B-cubed
- CEAF
- BLANC

6?

Les biais dans les modèles



Évaluation automatique des biais de genre dans des modèles de langue auto-régressifs

Ducél et al., 2024

- Evaluation de sept modèles génératifs face à la rédaction de lettres de motivation
- Détection des marqueurs morpho-syntaxiques dans les lettres
- Résultat : les modèles favorisent plus largement la génération de masculin face à un prompt « neutre »
- Les modèles étudiés « exacerbent des stéréotypes attestés en sociologie en associant les professions les professions stéréotypiquement féminines aux textes au féminin, et les professions stéréotypiquement masculines aux textes au masculin. » (Ducel et al., 2024)

L'écart genré varie selon la profession




FIGURE 4 – Distribution des genres pour les 10 domaines les plus biaisés. - FR_{Neutre}

L'écart genré varie selon la profession




FIGURE 6 – Distribution des genres pour les 10 domaines les plus biaisés. - IT_{Neutre}

L'impact sur l'environnement



- Changement climatique : l'IA est-elle un danger pour la planète ?
France Inter, 16/08/2024

Questionnaire de fin de cours

Disponible au lien suivant :

<https://framaforms.org/cours-bases-de-tal-m1-idl-lds-semaine-36-septembre-2024-1725617669>

Le même questionnaire sera proposé 6 mois après la fin du cours

Vos réponses sont anonymes

Au revoir !

